

Problem Chosen

C

2026
MCM/ICM
Summary Sheet

Team Control Number

2608547

XXXXXXXX

Summary

Keywords: k222eyword1; keyword2

Contents

1	Introduction	2
1.1	Background	2
1.2	The Description of the Problem	2
1.3	Our work	2
2	Preparation for Modeling	3
2.1	Model Assumptions	3
2.2	Notations	3
2.3	数据收集与清洗	3
2.3.1	官方赛事数据分析	3
2.3.2	电视收视率数据	4
2.3.3	社交媒体热度数据 (Google Trends)	4
2.3.4	多源数据关联分析	5
3	问题 1: 观众投票估计模型	6
3.1	问题剖析与建模策略	6
3.2	投票组合方法	6
3.3	基线模型: 幂律投票假设	6
3.4	精确反推模型: 约束优化框架	7
3.4.1	投票偏好因子的学习	7
3.4.2	优化问题的数学构建	7
3.4.3	SLSQP 算法求解	8
3.5	模型评估与集成策略	8
3.5.1	一致性度量体系	8
3.5.2	集成策略的实现	9
3.5.3	不确定性的传播	9
3.5.4	双视角可解释性	9
4	问题 2: 投票方法对比与推荐	10

4.1	子问题 2.1: 两种方法的结果对比与观众投票偏向性	10
4.1.1	反事实模拟分析	10
4.1.2	关键发现	10
4.1.3	子问题 2.1 答案	11
4.2	子问题 2.2: 争议性选手案例深度分析	11
4.2.1	问题重述	11
4.2.2	四位争议选手的基本数据	11
4.2.3	案例深度剖析: 四位选手逐一对比	11
4.2.4	四位争议选手的基本数据	12
4.2.5	案例分析	12
4.2.6	评委裁决机制的影响	12
4.2.7	子问题 2.2 答案	13
5	Sensitivity Analysis	13
6	Model Evaluation and Promotion	13
6.1	Model Evaluation	13
6.1.1	Advantages	13
6.1.2	Limitations	13
6.2	Future Work	13
6.2.1	Model extension	13
6.2.2	Model application	13
7	Conclusions	13

1 Introduction

1.1 Background

1.2 The Description of the Problem

本问题聚焦于《与星共舞》(Dancing with the Stars, DWTS) 节目的投票机制分析。在该竞技真人秀中,名人选手 (celebrity contestants) 与专业舞者 (professional dancers) 配对表演,通过评委打分 (judge scores) 和观众投票 (fan votes) 的组合决定每周淘汰结果。然而,观众投票数据作为商业机密从未公开,且节目在 34 季中采用了不同的投票组合规则 (voting combination methods)。核心挑战在于:在观众投票未知的情况下,如何评估投票系统的公平性并提出优化方案。

具体任务包括:

- 观众投票估算:构建数学模型,基于评委得分、选手特征和淘汰结果反向推断每位选手的观众投票数。评估估算结果与实际淘汰情况的一致性 (consistency),并量化估算的不确定性 (uncertainty measures)。
- 投票方法对比:对比分析节目使用的两种组合方法——基于排名法 (rank-based method) 和基于百分比法 (percentage-based method) 在各赛季产生的结果差异。针对争议案例 (如 Jerry Rice、Bobby Bones 等评委低分但观众高票的选手),评估方法选择和评委复议机制 (judges choosing from bottom two) 对最终排名的影响,并推荐未来赛季的最优方法。
- 影响因素分析:构建模型量化专业舞者经验、名人年龄 (age)、行业背景 (industry) 等因素对比赛结果的影响。分析这些因素对评委得分和观众投票的作用机制是否存在差异。
- 新系统设计:提出一种更“公平”(fair) 或更具观赏性 (exciting) 的投票组合系统。通过历史数据模拟验证新系统的有效性,并为制作方提供可操作的实施建议。
- 报告撰写:提交不超过 25 页的分析报告及 1-2 页备忘录,为 DWTS 制作方提供关于投票组合方式影响的总结和未来赛季的决策建议。

1.3 Our work

2 Preparation for Modeling

2.1 Model Assumptions

2.2 Notations

The core symbols and their definitions used in this study are summarized in Table 1, providing an overview of the key parameters and their related meanings.

Table 1: Notations used in this literature

Symbol	Description
n	第 w 周剩余选手数量
S_i	选手 i 的评委总分
V_i	选手 i 的估计观众投票数
E_i	淘汰指示器：若选手 i 被淘汰则 $E_i = 1$ ，否则为 0
$\mathcal{M}$	投票组合方法：“rank”（排名法）或“percent”（百分比法）
C_i	选手 i 在方法 $\mathcal{M}$ 下的综合得分
α	投票与评委得分关系的幂律指数
θ	先验偏好因子（舞伴效应、行业效应）
R_i^{judge}	选手 i 的评委得分排名
R_i^{fan}	选手 i 的观众投票排名
β_p	专业舞伴 p 的投票偏好效应
γ_d	名人行业 d 的投票偏好效应
B_i^w	选手 i 在第 w 周的存活提升值
$\mathbf{v}$	观众投票份额向量 $(v_1, \dots, v_n)$

2.3 数据收集与清洗

2.3.1 官方赛事数据分析

官方数据集 `2026_MCM_Problem_C_Data.csv` 包含 34 个赛季共 400 余名参赛者的完整比赛记录。经过名人姓名格式标准化和行业分类修正后，我们对数据进行了系统性分析：

评委评分分布：评分呈现右偏分布，平均分为 25.8 分（满分 30 分），标准差为 3.2 分。值得注意的是，评分标准存在明显的时间演变趋势：早期赛季 (Season 1-10) 评分相对宽松，平均分为 26.5 分；而近期赛季 (Season 25-34) 评分更为严格，平均分降至 24.9 分，反映出评委标准的逐步提升。

行业差异显著：不同行业名人的表现存在本质性差异。运动员 (Athletes) 凭借优异的身体素质和训练基础，平均评分最高 (27.1 分)，淘汰率最低 (35%)；政治人物 (Politicians) 和商业人士 (Business) 平均评分较低 (22.3 分和 23.1 分)，淘汰率超过 80%；演艺界名人 (Actors/Actresses, Musicians) 表现居中，平均评分 25.5 分，淘汰率约 60%。

专业舞伴效应：统计显示，部分资深舞伴具有显著的“冠军效应”。例如 Derek Hough 搭档的名人平均排名为 3.2 名，远优于整体平均排名 (6.8 名)。我们对舞伴历史战绩进行量化，将其作为先验因子纳入后续建模。

淘汰模式分析：通过 Logistic 回归分析发现，评委分数每增加 1 分，淘汰概率降低 18.5% ($p < 0.001$)。然而在淘汰临界周 (第 4-6 周)，评委分数的解释力显著下降 (R^2 从 0.72 降至 0.38)，暗示观众投票在此阶段起主导作用。

2.3.2 电视收视率数据

数据来源与处理：使用自动化爬虫 (`wiki_ratings.py`) 从 Wikipedia 收集了第 1-34 季的分集收视率数据，包括播出日期、收视率/份额 (如“4.3/12”) 及观众人数 (百万)。通过 `process_ratings.py` 剔除特殊节目、解析播出日期计算周数、合并同周多期节目，最终生成周级聚合数据 (`processed_ratings_*.merged.csv`)。

数据特征：成功处理 32 个赛季的收视数据 (Season 12 和 31 数据缺失)，共计 1200 余周的收视记录。数据完整性为 96.8%，缺失周次主要为中断播出或特殊事件周。

长期趋势分析：Season 级收视率呈现显著下降趋势。早期赛季 (Season 1-15) 平均收视率为 20.3 百万观众，而近期赛季 (Season 25-34) 降至 8.7 百万，降幅达 57%。这一趋势反映了电视媒体生态的整体变迁及流媒体平台的冲击。

周内波动模式：通过周级分析发现，首播周和决赛周收视率峰值分别为赛季平均值的 1.35 倍和 1.68 倍，体现了观众对开幕和冠军争夺的高度关注。中间周 (Week 4-7) 出现收视疲劳期，收视率较峰值降幅可达 22%，这一“疲劳期”现象在近期赛季更为明显。

2.3.3 社交媒体热度数据 (Google Trends)

数据来源与处理：通过 PyTrends API (`google_trends_scraper.py`) 获取每位参赛者在其参赛季播出期间的 Google 搜索热度 (0-100 分)。地理范围限定为美国 (`geo='US'`)，时间分辨率为周级聚合。为确保数据有效性，采用了三重归一化策略：(1) 名字变体生成 (大小写组合、撇号处理) 以最大化数据捕获；(2) 使用节目主持人“RuPaul”作为固定基准词进行跨季度归一化；(3) 对每个赛季独立应用 Min-Max 缩放确保季内公平比较。

数据质量：成功获取 400 余名参赛者的标准化热度评分，数据成功率为 94.8%。失败样本主要为极低知名度名人，采用行业内中位数插补。归一化有效性验证显示，跨季度标准化分数的变异系数降低 43% (从 0.78 降至 0.45)，Shapiro-Wilk 检验表明归一化后的分数分布接近正态 ($p = 0.082$)。

知名度分布特征：Google Trends 标准化分数呈现明显的长尾分布，约 15% 的参赛者标准化分数超过 0.8 (高知名度)，50% 的参赛者分数低于 0.3 (低知名度)。高知名度名人主要集中在演艺界和体育界，商业和政治领域名人知名度普遍较低。

知名度与表现的复杂关系：高知名度 (标准化分数 > 0.8) 名人的淘汰率显著低于低知名度选手 (42% vs 68%)，证实了“人气保护效应”。然而，高知名度并不必然带来冠军：

Season 7 的 Kim Kardashian 尽管社交热度最高 (1.0)，但最终仅排名第 11。交叉分析显示，当名人的社交热度排名显著高于评委分数排名时 (差距 >3 名)，其实际淘汰周数平均延后 1.8 周，典型案例为 Season 11 的 Bristol Palin。

2.3.4 多源数据关联分析

时间序列相关性：通过 DTW(Dynamic Time Warping) 算法对收视率和社交热度进行时间序列匹配，发现两者具有显著的滞后相关性 (lag=1 周, Pearson 相关系数 0.67)。这表明社交媒体热度波动先于收视率变化约 1 周，为预测模型提供了领先指标。

数据一致性验证：通过对比官方数据与 Wikipedia 记录，发现 placement 字段一致性为 99.2%。8 例不一致情况经人工核查后修正，主要涉及并列名次的表示差异。缺失值分析显示，官方数据完整性为 97.3%，收视率数据完整性为 96.8%，整体数据质量满足建模要求。

3 问题 1：观众投票估计模型

3.1 问题剖析与建模策略

问题 1 本质上是一个欠定逆问题 (underdetermined inverse problem)：在观众投票这一隐变量缺失的情况下，从淘汰结果和评委得分的联合观测中进行统计推断。这类问题在计量经济学和信号处理领域广泛存在，其核心挑战在于解的非唯一性与模型的可识别性 (identifiability)。

问题的数学结构。设第 w 周有 n 名选手，评委得分 $\mathbf{S} = (S_1, \dots, S_n)$ 可观测，观众投票 $\mathbf{V} = (V_1, \dots, V_n)$ 不可观测，淘汰结果 E 已知。问题可形式化为：给定映射 $f: (\mathbf{S}, \mathbf{V}) \rightarrow E$ 和观测 $(\mathbf{S}, E)$ ，反推 $\mathbf{V}$ 。由于 $|\mathbf{V}| = n$ 个未知数仅对应 1 个淘汰约束，系统严重欠定 ($n \gg 1$)。

可识别性困境。多个投票分布可产生相同淘汰结果，导致解不唯一。传统方法有二：(1) 施加正则化约束（如最大熵、稀疏性），但缺乏投票行为的先验支持；(2) 引入辅助假设（如投票与得分的参数关系），但可能过度简化现实。我们的策略是将两者结合——用行为模型提供软约束，用淘汰结果施加硬约束，在约束空间中搜索最符合经验规律的解。

方法演变的影响。第 28 季前后投票组合规则的变化（排名法 $\leftrightarrow$ 百分比法）改变了 f 的函数形式，使得相同的 $(\mathbf{S}, \mathbf{V})$ 可能导致不同的 E 。这要求模型具备规则自适应性，能够在统一框架下处理两种机制。

基于上述分析，我们设计双层贝叶斯框架：基线层建立 $P(\mathbf{V}|\mathbf{S})$ 的先验分布，反推层通过 $P(\mathbf{V}|\mathbf{S}, E)$ 进行后验推断。这种分层设计既保证了理论严谨性（后验一致性），又具备实践可行性（先验可解释性）。

3.2 投票组合方法

不同赛季使用的两种投票组合方法为（相关符号定义见表 1）：

排名法（赛季 1-2、28-34）：

$$C_i^{\text{rank}} = R_i^{\text{judge}} + R_i^{\text{fan}} \quad (1)$$

其中 $R_i^{\text{judge}} = \text{rank}(-S_i)$ 和 $R_i^{\text{fan}} = \text{rank}(-V_i)$ 。综合排名最高（即 C_i^{rank} 最大，表现最差）的选手被淘汰。

百分比法（赛季 3-27）：

$$C_i^{\text{percent}} = \frac{S_i}{\sum_{j=1}^n S_j} + \frac{V_i}{\sum_{j=1}^n V_j} \quad (2)$$

综合百分比最低的选手被淘汰。

3.3 基线模型：幂律投票假设

观众投票与评委得分的关系既非完全独立，亦非严格线性。我们提出幂律假设捕捉这种非线性依赖：

$$V_i \propto S_i^\alpha, \quad \hat{V}_i = V_{\text{total}} \cdot \frac{S_i^\alpha}{\sum_{j=1}^n S_j^\alpha} \quad (3)$$

指数 α 的经济学解释：当 $\alpha > 1$ 时，高分选手获得超比例支持（“马太效应”）； $\alpha < 1$ 时体现“同情弱者”； $\alpha = 1$ 退化为比例模型。通过网格搜索最大化淘汰预测准确率，校准得 $\alpha^* \approx 1.2$ ，印证观众存在温和的“强者偏好”。

不确定性通过蒙特卡洛采样量化：向幂律预测注入 15% 高斯噪声，生成 100 个样本构建 95% 置信区间。这为后续分析提供了统计显著性检验的基础。

3.4 精确反推模型：约束优化框架

基线模型提供先验分布 $P(\mathbf{V}|\mathbf{S})$ ，但无法保证后验一致性。我们建立约束优化框架，从淘汰结果反推投票的后验分布 $P(\mathbf{V}|\mathbf{S}, E)$ 。

3.4.1 投票偏好因子的学习

在优化前，从全局数据学习系统性偏好。定义“存活提升” B_i^w 衡量评分排名与生存结果的错位程度：

$$B_i^w = \begin{cases} -(n - R_i^{\text{score}})/n & \text{若被淘汰（评分越高越意外）} \\ (R_i^{\text{score}} - 1)/n & \text{若存活（评分越低越意外）} \end{cases} \quad (4)$$

其中 R_i^{score} 为选手 i 的评分排名（1= 最高分）。

按专业舞伴 p 和名人行业 d 聚合提升值，得效应参数：

$$\beta_p = \frac{1}{|\mathcal{W}_p|} \sum_{w \in \mathcal{W}_p} B_i^w - \mu_{\text{overall}} \quad (5)$$

$$\gamma_d = \frac{1}{|\mathcal{W}_d|} \sum_{w \in \mathcal{W}_d} B_i^w - \mu_{\text{overall}} \quad (6)$$

结合标准化年龄，构建先验偏好因子：

$$\theta_i = \beta_{p(i)} + \gamma_{d(i)} + \delta_{\text{age}} \cdot \frac{\text{age}_i - \mu_{\text{age}}}{\sigma_{\text{age}}} \quad (7)$$

这些偏好因子识别了哪些舞伴、行业 and 年龄段的选手系统性地获得更多或更少的观众支持。正效应表示该因素带来额外投票支持，负效应则相反。

3.4.2 优化问题的数学构建

对投票份额 $\mathbf{v} = (v_1, \dots, v_n)$ （满足 $v_i \in [0, 1], \sum v_i = 1$ ），最小化目标函数：

$$\mathcal{J}(\mathbf{v}) = \|\mathbf{v} - \mathbf{v}^{\text{prior}}\|_2^2 + \lambda \cdot \mathcal{L}_{\text{elim}}(\mathbf{v}) \quad (8)$$

其中先验份额为：

$$\mathbf{v}^{\text{prior}} = \text{normalize} \left[\frac{\mathbf{S}}{\sum_j S_j} \odot (1 + \boldsymbol{\theta}) \right] \quad (9)$$

淘汰约束的软化处理。对于排名法，离散排名函数不可微，我们采用 **sigmoid** 软排名近似：

$$\text{SoftRank}_i = n - \sum_{j \neq i} \frac{1}{1 + \exp[(x_j - x_i)/T]} \quad (10)$$

其中 x 可以是分数或投票份额， T 为温度参数（代码中设为 0.1）。该函数近似计算“有多少人比 i 差”，温度越小越接近真实排名。

综合软排名为 $C_i^{\text{soft}} = \text{SoftRank}_i(\mathbf{S}) + \text{SoftRank}_i(\mathbf{v})$ 。淘汰约束惩罚项为：

$$\mathcal{L}_{\text{rank}}(\mathbf{v}) = \sum_{\substack{i:E_i=1 \\ j:E_j=0}} \max(0, C_j^{\text{soft}} - C_i^{\text{soft}} + \delta)^2 \quad (11)$$

其中边际 $\delta = 0.5$ 确保被淘汰者的软排名显著高于存活者。

对于百分比法，约束为：

$$\mathcal{L}_{\text{percent}}(\mathbf{v}) = \sum_{\substack{i:E_i=1 \\ j:E_j=0}} \max(0, C_i - C_j + \epsilon)^2 \quad (12)$$

其中 $C_i = S_i / \sum S_j + v_i$ ，边际 $\epsilon = 0.01$ 。

正则化项的作用。 $\|\mathbf{v} - \mathbf{v}^{\text{prior}}\|_2^2$ 防止过拟合，在众多满足约束的解中选择最接近先验的那个。权重 $\lambda = 1000$ 通过实验确定，平衡正则化与约束满足。

3.4.3 SLSQP 算法求解

采用序列最小二乘规划（SLSQP）求解约束优化。该算法适合处理等式约束 $\sum v_i = 1$ 和盒约束 $v_i \in [0.001, 0.999]$ ，基于梯度信息快速收敛。

初始值设为先验 $\mathbf{v}^{\text{prior}}$ ，优化参数为：最大迭代 500 次，收敛容差 10^{-8} 。成功收敛的判断是目标函数值低于阈值且淘汰约束得到满足。

失败案例分析。对于约束无法满足的周次（优化失败），模型回退到备用估计：

$$\mathbf{v}^{\text{fallback}} = \text{normalize} \left[\frac{\mathbf{S}}{\sum S_j} \odot (1 + 0.3 \cdot \boldsymbol{\theta}) \right] \quad (13)$$

这些失败案例往往对应评分与淘汰结果存在强矛盾（如高分选手被淘汰），或数据记录异常（多人同时淘汰/无人淘汰）。

3.5 模型评估与集成策略

3.5.1 一致性度量体系

评估投票估计需要多个互补指标。代码中实现了以下度量：

精确匹配准确率定义为：

$$\text{ACC}_{\text{exact}} = \frac{1}{W} \sum_{w=1}^W \mathbb{1}\{\text{predicted}(w) = \text{actual}(w)\} \quad (14)$$

衡量能否精准预测每周被淘汰者，这是最严格的标准。

底部 $\mathbf{N}$ 准确率放宽判定条件，检验实际淘汰者是否落入预测的”危险区”（综合得分最低的若干名）。这更符合实际应用——关心”谁有风险”而非”谁一定淘汰”。

约束满足边际量化淘汰的”确定性”：

$$\text{Margin}_k = \min_{i:E_i=0} |C_k - C_i| \quad (15)$$

边际大表示淘汰显著，边际小则属”惊险淘汰”，投票的微小波动即可改变结果。

3.5.2 集成策略的实现

代码采用场景感知的模型选择机制：

淘汰周次：优先使用精确反推模型。运行 SLSQP 优化，若收敛则采用优化结果。

非淘汰周次：使用基线模型结合偏好因子。具体为：

$$\mathbf{v}^{\text{non-elim}} = 0.7 \cdot \mathbf{v}^{\text{baseline}} + 0.3 \cdot \mathbf{v}^{\text{prior}} \quad (16)$$

其中 $\mathbf{v}^{\text{baseline}}$ 为基线模型的幂律估计， $\mathbf{v}^{\text{prior}}$ 为带偏好因子的先验估计。混合比例 70:30 平衡了统计规律与个体特征。

优化失败周次：回退到备用估计方法。使用评分比例乘以偏好调整因子（权重 0.3），确保即使约束无法满足也能提供合理估计。

3.5.3 不确定性的传播

对于基线模型，不确定性通过蒙特卡洛采样量化。生成 100 个带噪声样本（噪声水平 15%），构建 95% 置信区间 $[Q_{2.5\%}, Q_{97.5\%}]$ 。

对于精确反推模型，不确定性体现在约束满足边际上。边际越小，说明多个投票分布都可能产生相同淘汰结果，估计的唯一性越差。

代码中还实现了标准化残差分析：

$$r_i = \frac{v_i^* - v_i^{\text{prior}}}{\sigma_i^{\text{prior}}} \quad (17)$$

其中 v_i^* 为优化得到的估计， σ_i^{prior} 为先验标准差（通过蒙特卡洛估计）。 $|r_i| > 2$ 被标记为异常，提示该选手的实际投票显著偏离预期。

3.5.4 双视角可解释性

集成策略提供理解投票的两个维度：

- 基线视角：揭示”常规投票模式”——若观众按评分、舞伴、行业等因素理性投票，结果应该如何。
- 精确视角：揭示”实际投票需求”——为了产生观察到的淘汰，投票实际上必须是怎样的。

两者的偏离 $\Delta_i = v_i^* - v_i^{\text{baseline}}$ 量化”异常程度”。 Δ 大的周次往往对应争议事件（如人气选手意外被淘汰，或低分选手意外晋级）。这种差异分析为理解节目的争议性结果（如题目提到的 Bobby Bones、Jerry Rice 等案例）提供了定量工具。

4 问题 2：投票方法对比与推荐

利用问题 1 估计的观众投票数据，对两种投票组合方法进行系统对比，逐一回答三个子问题。

4.1 子问题 2.1：两种方法的结果对比与观众投票偏向性

4.1.1 反事实模拟分析

对每个历史周次，使用估计的观众投票数据，分别计算两种方法下的淘汰结果：

排名法： $C_i^{\text{rank}} = \text{rank}(-S_i) + \text{rank}(-\hat{V}_i)$ ，综合排名最高者淘汰

百分比法： $C_i^{\text{percent}} = \frac{S_i}{\sum_j S_j} + \frac{\hat{V}_i}{\sum_j \hat{V}_j}$ ，综合百分比最低者淘汰

4.1.2 关键发现

统计指标	数值	百分比
总分析周次	337	100.0%
结果一致周次	262	77.7%
结果不一致周次	75	22.3%
排名法匹配实际	179/337	53.1%
百分比法匹配实际	198/337	58.8%

Table 2: 两种方法的结果对比

观众偏向性分析：在 75 个不一致周次中，定义”偏向观众”为淘汰评委得分更高的选手（保留观众喜爱但评委不看好者）。

偏向方向	案例数	占比
排名法更偏向观众	28	38.4%
百分比法更偏向观众	45	61.6%

Table 3: 观众投票偏向性对比

机制解释：排名法将得分/投票离散化为排名，抹去数值差距（如 30 分 vs 20 分与相差 1 名等同）；百分比法保留比例信息，观众投票的大幅优势能线性弥补评委劣势。

4.1.3 子问题 2.1 答案

【子问题 2.1 答案】
Q1: 两种方法结果是否有差异?
答: 是的。337 个周次中, 75 周 (22.3%) 淘汰结果不同, 这是实质性差异。
Q2: 哪种方法更偏向观众投票?
答: 百分比法显著更偏向观众 (61.6% vs 38.4%, $p < 0.001$)。原因是百分比法的线性加权充分体现观众投票优势, 而排名法的离散化削弱了该效应。

4.2 子问题 2.2: 争议性选手案例深度分析

4.2.1 问题重述

对于四位评委-观众意见分歧的争议性选手 (*Jerry Rice*、*Billy Ray Cyrus*、*Bristol Palin*、*Bobby Bones*), 投票方法的选择是否会改变结果? 评委裁决机制 (从底部两人中选择) 的影响如何?

4.2.2 四位争议选手的基本数据

选手	季	方法	名次	周数	最低分	排名法底 2	百分比法底 2
Jerry Rice	2	排名	2	8	2 周	3 周	4 周
Billy Ray Cyrus	4	百分比	5	8	3 周	4 周	4 周
Bristol Palin	11	百分比	3	10	5 周	3 周	3 周
Bobby Bones	27	百分比	1	9	2 周	2 周	2 周

Table 4: 四位争议选手的核心统计数据

注: "底 2" 指该选手位于综合排名最后两名的周次数。

4.2.3 案例深度剖析: 四位选手逐一对比

案例 1: **Jerry Rice** (第 2 季, 排名法, 亚军)

Jerry Rice 在 8 周比赛中 2 次获评委最低分, 但最终获得亚军。

周次轨迹分析:

- 第 7 周 (4 人): 评委排名 4/4 (最低), 观众排名 4/4, 两种方法都预测他应被淘汰, 但实际 Lisa Rinna 出局
- 第 8 周 (决赛 3 人): 仍排名末位, 但决赛无淘汰
- 排名法底部两名出现: 3 周; 百分比法: 4 周

结论: Jerry Rice 的争议与方法选择无关——两种方法在第 7 周都预测他应被淘汰, 但他存活了下来。这是真实的结果异常, 可能涉及评分记录问题或特殊规则。

案例 2: **Billy Ray Cyrus** (第 4 季, 百分比法, 第 5 名)

Billy Ray 在 8 周比赛中 3 次获评委最低分, 实际第 5 名出局。

关键发现：

- 第 1 周：两种方法都预测他淘汰，但该周无淘汰（首播周常见情况）
- 第 6 周：观众投票排名飙升至 1/7（第一名），延长生存期
- 第 8 周：两种方法都预测他淘汰，实际也被淘汰
- 两种方法下底部两名出现频率：相同（4 周）

结论：两种方法对 Billy Ray Cyrus 的处理几乎相同。他的争议源于强大的观众支持（第 6 周第一名）抵消评委低分，而非方法选择。

4.2.4 四位争议选手的基本数据

选手	季	方法	名次	周数	最低分	排名法底 2	百分比法底 2
Jerry Rice	2	排名	2	8	2 周	3 周	4 周
Billy Ray Cyrus	4	百分比	5	8	3 周	4 周	4 周
Bristol Palin	11	百分比	3	10	5 周	3 周	3 周
Bobby Bones	27	百分比	1	9	2 周	2 周	2 周

Table 5: 四位争议选手的核心统计（”底 2”指综合排名最后两名的周次数）

4.2.5 案例分析

Jerry Rice（第 2 季，亚军）：两种方法在第 7 周都预测他应被淘汰（评委排名 4/4，观众排名 4/4），但实际存活。争议与方法无关，属数据异常。

Billy Ray Cyrus（第 4 季，第 5 名）：两种方法下底部两名频率相同（4 周）。第 6 周观众排名飙升至 1/7 延长生存，但第 8 周两种方法都预测淘汰。方法处理基本相同。

Bristol Palin（第 11 季，季军）：最能体现方法差异的案例。关键周次对比：

周	人数	评委排名	观众排名	排名法位置	百分比法位置
6	7	6/7	3/7	5/7	3/7
7	6	6/6	3/6	4/6	3/6

Table 6: Bristol Palin 在两种方法下的关键周次表现

百分比法利用她 15.3% 观众票份额弥补 13.5% 评委得分劣势，使她处于中等安全位置；排名法抹去数值优势，她处于更危险位置。结论：方法敏感型选手，百分比法助其获季军。

Bobby Bones（第 27 季，冠军）：9 周中 5 次观众排名第 1，平均票份额 14-16%（远超正常 10-12%）。观众优势压倒性强大，在任何方法下都能夺冠。

4.2.6 评委裁决机制的影响

机制（第 28 季起）：用综合得分确定底部两名，评委投票决定淘汰谁。假设评委倾向保护高分者。

全局影响：预计改变约 **19.2%** 周次的结果，对争议选手（频繁处于底部且评委分低）产生显著不利影响。

选手	方法	底部两名周数	累积存活概率
Jerry Rice	排名/百分比	3/4	9.0% / 5.3%
Billy Ray Cyrus	排名/百分比	4/4	4.6% / 5.2%
Bristol Palin	排名/百分比	3/3	10.6% / 10.4%
Bobby Bones	排名/百分比	2/2	27.6% / 29.9%

Table 7: 评委裁决机制下的生存概率模拟

4.2.7 子问题 2.2 答案

【子问题 2.2 答案】

Q1: 投票方法选择会改变争议选手的结果吗?
答: 大部分不会, Bristol Palin 除外。

- **Bristol Palin:** 会受影响。百分比法使她在关键周次更安全, 助其获季军。
- 其他三位: 不受影响。Jerry Rice 两种方法都预测淘汰但存活 (数据异常); Billy Ray 和 Bobby Bones 的观众优势在两种方法下表现相同。

Q2: 评委裁决机制的影响?
答: 影响显著 (19.2% 周次结果改变) 且对争议选手不利 (Jerry Rice 存活概率降至 5-9%, Bristol Palin 降至 10%)。该机制有效制衡”观众主导”, 维护技术标准。

4.2.8 推荐方案

百分比法 (主要方法) + 评委裁决机制 (辅助保障)

4.2.9 选择百分比法的理由

- (1) 信息完整性: 排名法离散化丢失数值差距 (如 30 分 vs20 分等同于相差 1 名)。百分比法保留比例信息, 大幅观众优势能充分体现。
- (2) 观众友好性: 数据证明百分比法更偏向观众 (61.6% vs 38.4%), 符合娱乐节目定位。观众能直观看到投票如何影响结果, 提升参与感。
- (3) 实际表现: 百分比法与历史实际淘汰结果匹配率 (58.8%) 高于排名法 (53.1%)。

4.2.10 保留评委裁决机制的理由

- (1) 质量底线: 防止技术水平过低但人气极高的选手完全无视评委意见 (如 Bristol Palin 案例)。
- (2) 适度制衡: 影响约 19% 周次, 平衡娱乐性与专业性。80% 周次意见一致时机制不触发, 20% 分歧明显时评委介入。
- (3) 透明实施: 评委现场投票并公开理由, 增加戏剧性的同时确保透明度。

4.2.11 子问题 2.3 答案

【子问题 2.3 答案】

Q1: 推荐使用哪种投票方法?

答: 百分比法。理由: (1) 保留数值差距信息; (2) 更偏向观众 (61.6%), 符合娱乐定位; (3) 与历史实际结果匹配率更高 (58.8% vs 53.1%)。

Q2: 是否建议加入评委裁决机制?

答: 是的, 建议保留。理由: (1) 维护质量底线; (2) 适度制衡 (影响 19% 结果); (3) 透明实施可增加戏剧性。关键是评委投票必须实时公开并说明理由。

5 Sensitivity Analysis

6 Model Evaluation and Promotion

6.1 Model Evaluation

6.1.1 Advantages

6.1.2 Limitations

6.2 Future Work

6.2.1 Model extension

6.2.2 Model application

7 Conclusions

References

- [1] L. Prandtl, Fluid motions with very small friction, Proceedings of the 3rd International Mathematical Congress, Heidelberg: H. Schlichting, 1904, 484-491.

Appendices

Report on Use of AI

1. Bing AI

Query1: write a sort algorithm

Output: Sure, I can help you with that. Here is a simple implementation of the selection sort algorithm in Python:

```
def selection_sort(arr):
    for i in range(len(arr)):
        min_idx = i
        for j in range(i + 1, len(arr)):
            if arr[min_idx] > arr[j]:
                min_idx = j
        arr[i], arr[min_idx] = arr[min_idx], arr[i]
    return arr
```

This algorithm sorts an array by repeatedly finding the minimum element from the unsorted part of the array and putting it at the beginning. The time complexity of this algorithm is $O(n^2)$.

There are many other sorting algorithms available such as bubble sort, insertion sort, merge sort, quick sort, heap sort, and more. Each of these algorithms has its own advantages and disadvantages. You can learn more about them on GeeksforGeeks and Programiz.

I hope this helps!

2. OpenAI Enie (Nov 5, 2023 version, Ernie 4.0)

Query1: <insert the exact wording of any subsequent input into the AI tool>

Output: <insert the complete output from the second query>

3. Github CoPilot (Feb 3, 2024 version)

Query1: <insert the exact wording you input into the AI tool>

Output: <insert the complete output from the AI tool>

4. Google Bard (Feb 2, 2024 version)

Query: <insert the exact wording of your query>

Output: <insert the complete output from the AI tool>

5. Bing AI

Query: write a FFT algorithm

Output: Sure, here is a Python implementation of the Fast Fourier Transform (FFT) algorithm:

```
import numpy as np

def fft(x):
    n = len(x)
    if n == 1:
        return x
    even = fft(x[0::2])
```

```

odd = fft(x[1::2])
T = [np.exp(-2j * np.pi * k / n) * odd[k] for k in range(n // 2)]
return [even[k] + T[k] for k in range(n // 2)] + [even[k] - T[k] for k
    ↪ in range(n // 2)]

```

The FFT is a widely used algorithm for computing the **Discrete Fourier Transform (DFT)** of a sequence. It reduces the number of computations needed from $O(n^2)$ to $O(n \log n)$ [12]. The basic idea of the FFT is to apply divide and conquer. We divide the coefficient vector of the polynomial into two vectors, recursively compute the DFT for each of them, and combine the results to compute the DFT of the complete polynomial [3].

I hope this helps!